

TOVNET · SEG PROJECT REVIEW

TOVNET-SEG

CCTV 고해상도 영상 기반 실시간 수면 조류(녹조·적조) 세그멘테이션 시스템

개발 기간 2026.05 ~ 2026.07 (Phase 0 – Phase 6)

핵심 모델 OneFormer (Swin-Large, $\approx 236\text{M}$ params)

최종 성능 Test mIoU 0.770 · 평균 지연 646ms

원개발 성균관대학교 연구진 · 기술자료 정리·발표 양호용

프로젝트 개요

CCTV 영상 속 수면 부유 조류를 픽셀 단위로 분리하여, 점유율 계산 → 임계치 초과 시 알람·증거 저장까지 이어지는 엔드투엔드 파이프라인

01



Full Resolution 단일 추론

타일링 오버헤드를 제거하고 1920×1088
전신 입력 → 단일 추론 → 결과 크롭 체계로
전환

02



DB 모니터링 기반 동적 제어

정적 실행에서 벗어나, DB를 주기적으로
폴링해 CCTV 추가/삭제를 실시간 감지하는
서버 아키텍처

03



모듈형 계층 구조

utils → events → inference/ingestion/output →
core로 이어지는 단방향 의존성 규칙 확립

GPU

RTX A5000 · 24GB VRAM

모델

OneFormer Swin-Large

플랫폼 DB

MySQL · 내부 플랫폼 DB

네트워크

WireGuard VPN 원격 서버

실시간 처리 파이프라인

RTSP 수집부터 알람·대시보드 송출까지, 5단계 파이프라인으로 구성된 프로덕션 시스템




기술 스택

프레임워크	PyTorch · Transformers ≥ 5.9.0
정밀도	bfloat16 / FP16 자동 혼합 정밀도(AMP)
스트리밍	FFmpeg NVDEC · HLS (RAM 디스크)
웹 서버	Flask (MJPEG + 대시보드)
연동	REST API · Redis 캐시 · SQLite WAL

설계도가 아닌, 실제 가동 중인 시스템

RTSP 수집부터 알람·대시보드 송출까지 전 구간이 코드 레벨로 검증된 프로덕션 아키텍처



이것이 비즈니스에 의미하는 것

- 도입 리스크 최소화

프로토타입이 아닌 실동작 코드. PID 구동 확인, 즉시 파일럿 배포 가능

- 운영 인건비 절감

EventHandler가 알람·증거 저장을 자동화 → 상시 육안 모니터링 인력 불필요

- 확장 가능한 구조

카메라 1대 추가 시 Ingestor 스레드만 증설 → 다수 CCTV 사이트로 선형 확장

- 표준 인프라 호환

HLS·MJPEG·REST API 등 범용 프로토콜 사용 → 기존 관제 대시보드에 즉시 연동

모델 아키텍처 진화: 3단계 선택 과정

실시간성과 정확도의 균형을 찾기 위해 두 차례의 구조 전환을 거쳐 최종 모델을 확정

Phase 0

베이스라인

DeepLabV3+

ResNet50 · ImageNet

정밀도 ▲ / 속도 ▼

다중 스케일 특징 추출은 우수하나 FPS가 낮아
실시간 서비스에 부적합, Batch Queue Full 빈번

Phase 1

경량화 시도

Fast-SCNN

경량 실시간 모델

속도 ▲ / 정밀도 ▼

추론 속도는 크게 개선됐지만 조류 경계가
불명확해 정밀도가 저하, 하이브리드 운용
필요

Phase 2

최종 선택

OneFormer

Swin-Large · ≈236M

정밀도 ▲ / 속도 ▲

Universal Segmentation + ADE20K 사전학습을
sludge 도메인으로 전이. 최종 채택 모델


KEY BREAKTHROUGH

타일링 제거 → Full Resolution 단일 추론

“GPU 사용량은 높은데 FPS가 낮다” — 병목의 원인은 연산량이 아닌 타일 호출 횟수와 전처리 오버헤드였음

평균 지연시간 (ms)


Phase 2 전환 시점 벤치마크(2026-06-15)



↓ 2.3배 개선

정확도 (mIoU)

Phase 2 전환 시점 벤치마크(2026-06-15) · 참고: 최종 검증 mIoU 는 '최종 성능 지표 슬라이드'에서 별도 제시



+0.0286 상승

32-pixel Alignment

1080→1088 패딩으로 Swin Transformer 차원 요구사항 충족

bfloat16 AMP


torch.cuda.amp.autocast()로 FP16 추론 가속, 최대 VRAM 6.33GB

Zero-copy 아키텍처

PyTorch↔Numpy 변환 시 메모리 복사 최소화

1픽셀의 오차가 알람의 신뢰도를 무너뜨린다

타일 경계에서 발생한 예측 불일치가 어떻게 오탐·미탐으로 이어지는지, 실제 검증 로그로 확인



비즈니스 리스크

- **오탐(False Alarm)**
 경계 불일치 영역이 오검출되어 불필요한 알람·현장 출동 비용 발생
- **미탐(Missed Alarm)**
 끊긴 영역만큼 실제 점유율이 과소 계산 → 임계치 미달로 경보 누락
- **신뢰도 하락**
 동일 조류를 타일마다 다르게 판정 → 운영자의 시스템 신뢰 저하

해결 → Full Resolution 전환

타일 경계 자체를 제거해 판정 불일치 원천 차단, 오탐·미탐 리스크를 구조적으로 해소

데이터셋 구성 및 학습 전략

1,238

원본-마스크 이미지 쌍

Train 866장 (70%)

Val 248장 (20%)

Test 124장 (10%)

이미지 레벨 분리로 Data Leakage 방지 · 4개
CCTV 소스에서 수집(6-1/6-2/9-1/Sokheng)

Hybrid Loss Function

$0.5 \times \text{BCEWithLogitsLoss} + 0.5 \times \text{DiceLoss}$

조류 픽셀이 전체의 1~3% 미만인 극심한 클래스 불균형 문제를 DiceLoss로 보완

Optimizer	AdamW (lr=3e-4, weight decay=1e-4)
Scheduler	CosineAnnealingLR
Precision	bfloat16 / FP16 Mixed Precision (AMP)

수면 특화 데이터 증강 (Albumentations)

ColorJitter

빛 반사·조명 변화 대응

GaussianBlur / MotionBlur

흐릿한 경계·수면 파동 대응

RandomBrightnessContrast

안개·흐림 조건 모방

Horizontal/Vertical Flip

위치 불변성 및 저각도 CCTV 모방

PERFORMANCE RESULTS

최종 성능 지표

Full Resolution 전환과 모델 최적화를 거쳐 검증된 최종 시스템 성능

0.770

Test mIoU

0518/0519 최신 데이터 기준,
key_remap.py 검증 재현

646ms

평균 추론 지연

Tiling 대비 2.3배 개선

6.33GB

최대 VRAM 사용량

RTX A5000 24GB 中 안정적 여유

30초

DB 폴링 주기

CCTV 추가/삭제 실시간 반영


평가 방식

IoU(Jaccard Index), F1-Score, Pixel Accuracy를 최신 데이터(0518/0519 촬영분)에 대해 산출 — 검증셋 대비 테스트셋 일반화 격차(Domain Shift)를 지속 모니터링

F1-Score(중요도 ↑) · Pixel Accuracy(클래스 불균형으로 과신 경향 有, 참고 지표)

Test mIoU, 왜 이 지표로 성능을 검증했나

AI가 찾아낸 조류 영역이 정답과 얼마나 겹치는지를 수치화한 지표 — 모델이 한 번도 보지 않은 데이터로 채점



핵심 포인트

- mIoU란?

정답 영역과 AI 예측 영역이 겹치는 정도를 나타낸 정확도 지표(0~1)

- 왜 "Test" 데이터인가

학습에 쓰지 않은 데이터로 채점 → 실제 현장 배포 시 기대 성능을 정직하게 보여줌

- 0.770의 의미

조류 영역의 약 77%를 정확히 검출 (0518/0519 최신 데이터로 검증 재현)

핵심 → 정직한 성능 지표

Test 데이터는 모델이 한 번도 본 적 없는 데이터라, 실전 배포 시 기대할 수 있는 성능에 가장 가까운 숫자입니다

기술적 난제와 검증된 해결 과정

발생 현상 → 근본 원인 분석 → 정량적 해결책, 3단계 진단 프로세스로 총 12건의 이슈를 해결

2026-06-10

OOM-Killer 강제 종료

현상

python3 프로세스 15GB RAM 점유 후 OS 강제 종료

원인

dmesg 로그 분석: 스트림 재연결 시 큐가 무제한으로 누적

해결

BatchScheduler에 Skip-to-Latest 전략 + Hard Cap 적용

2026-06-10

모델 웨이트 정합성 오류

현상

웨이트 리맵핑 실패로 모델이 무작위 초기값으로 동작

원인

transformers 라이브러리 버전 불일치 (445개 키 불일치)

해결

key_remap.py 리맵핑 + verify_load.py로 무결성 검증, mIoU 0.770 재현

2026-06-15

타일링 스티칭 아티팩트

현상

타일 경계에서 예측 불연속, GPU 커널 호출 오버헤드 과다

원인

1080p 처리 시 수십 개 타일 생성 → 반복 호출·중복 연산

해결

Full Resolution 단일 추론 전환으로 완전 제거 (Latency 2.3배 개선)

모듈형 아키텍처로의 전환

단일 실행 스크립트에서, 단방향 의존성을 갖는 계층형 서버 구조로 재설계



common → utils → inference/ingestion/output → events → core (단방향 의존성, 순환 참조 방지)

현재 시스템 운영 현황

2026-07-12 기준, 모듈형 아키텍처 v2.0으로 안정적으로 가동 중

● 정상 구동 중

PID	2404769 (정상 구동)
아키텍처	모듈형 계층 구조 v2.0
추론 엔진	OneFormer Swin-Large · Full Resolution (1920×1088)
DB 모니터링	30초 폴링 주기 · 동적 스트림 배포
활성화 정책	첫 추론 결과 브로드캐스트 후 enabled=1 업데이트 (Deferred Activation)
문서화	ARCHITECTURE.md · DEVELOPER_GUIDE.md 최신화 완료

향후 개선 방향

단기 (High Priority)

- TTA 적용

mIoU +0.02~0.05, Latency 1.5~2배 증가 예상

- Hard Example Mining

저조도·안개 등 취약 샘플 집중 학습

- Dynamic Thresholding

이미지별 적응형 임계값으로 오탐 감소

중장기 (Medium Priority)

- ONNX/TensorRT 배포

PyTorch 런타임 없이 경량 추론

- Multi-Camera Fusion

카메라 가림·결손 대응력 향상

- Temporal Consistency

프레임 간 일관성 강제, flickering 감소

장기 (Exploration)

- Self-Supervised Pretraining

소수 라벨로 높은 성능 달성

- Continual Learning

신규 카메라·계절 조건 점진 적응

감사합니다

TOVNET-SEG는 Full Resolution 전환과 모듈형 아키텍처를 통해 실시간성과 정확도를 함께 확보했으며, 30초 폴링 기반 동적 제어 서버로 안정적으로 운영되고 있습니다.

Q & A